

Relatório de Auditoria Técnica e Conformidade

Voice of Customer Intelligence com RAG e Camada Analítica — Olist

Disciplina:	Tech Challenge — Fase 4 (Deep Learning and NLP)	Equipe:	Grupo 99 (Gustavo Schutt, Tainá Julianotti, Wilker Cunha)
Repositório:	github.com/gustavoschutt/Tech-Challenge-Fase-4	LLM Provedor:	Google Gemini 3.8 Flash (configuração oficial homologada)
Data:	Outubro / 2026	Veredito:	Aprovado com Excelência — Pipeline 100% Operacional

1. Sumário Executivo da Auditoria

O projeto **Voice of Customer Intelligence** foi submetido a uma rigorosa bateria de auditoria técnica ponta a ponta, cobrindo Engenharia de Software, Engenharia de Dados, Information Retrieval (IR/NLP) e Inteligência Artificial Generativa com Guardrails (RAG). Todos os componentes foram validados em ambiente real de execução, comprovando estabilidade operacional, integridade matemática e contenção total de alucinações.

Dimensão Auditada	Status	Evidência Objetiva / Métrica Verificada
Testes Automatizados	100% Pass	30/30 testes executados com sucesso em 2,82s (unidades e integração).
Engenharia de Dados (ETL)	Conforme	42.138 documentos indexados, 5 PIIs mascaradas, 0 imputações textuais indevidas.
Pipeline RAG Qualitativo	Conforme	Busca híbrida com fusão RRF, reranker cross-encoder e citações estritas [E1] . . [En].
Camada Analítica Agregadora	Conforme	Roteamento automático para perguntas quantitativas; contagens sobre 98.410 avaliações.
Gate de Abstenção / Guardrail	Conforme	Bloqueio ativo de consultas sem respaldo factual (ex.: "Pix"), eliminando alucinações.
Notebooks (01 a 04)	100% Executados	44/44 células de código executadas em ordem sequencial com saídas e gráficos salvos.
Auditoria Humana de Temas	94,9% Precisão	298 acertos em 314 avaliações ativas auditadas por Gustavo (auditoria_temas.csv).
Auditoria de Fidelidade	100% Fidelidade	72 frases auditadas: 69 com sustentação total e 3 parciais (0 não sustentadas).
Controle de Versão (Git)	Sincronizado	Repositório GitHub atualizado na branch main, working tree limpa e .env seguro.

Destaque de Engenharia: Solução para a Falha Clássica de Agregação em RAG

Modelos RAG convencionais falham catastróficamente ao responder perguntas do tipo *"quais os principais problemas e suas porcentagens?"*, pois o LLM alucina métricas tentando extrapolar o conjunto restrito do top-k recuperado. Este projeto resolve isso elegantemente através da **bifurcação de intenção**: perguntas pontuais vão para o RAG semântico com citações, enquanto perguntas de frequência acionam uma **Camada Analítica Determinística** baseada em taxonomia auditada sobre toda a base.

2. Resultados dos Testes Práticos Executados

A. Teste de Pergunta Específica (RAG Híbrido + Re-ranking + LLM Gemini)

Execução de consulta qualitativa com recuperação semântica e léxica:

```
python scripts/perguntar.py "O que os clientes relatam sobre atrasos na entrega?"
```

Status retornado: ok · Modo: rag · Filtros: nenhum

Resumo Gerado: Os clientes relatam a ocorrência de atrasos na entrega dos produtos, destacando a falta de satisfação ou informações, além de casos em que o pedido ainda não chegou ou veio incompleto [E2][E3][E4][E5][E6][E7][E8].

- Falta de comunicação: Clientes apontam atraso sem que a loja dê satisfação ou consideração [E2][E3].
- Não recebimento do produto: Clientes aguardando entrega em atraso ou afirmando que a loja não entrega [E3][E7][E8].
- Entrega tardia e incompleta: Relato de produto entregue com atraso e faltando outros itens [E6].
- Ocorrência de atraso: Clientes apontam pontualmente atraso na entrega [E4][E5].

Evidências auditadas vinculadas à resposta:

Rótulo	Review ID	Nota	Categoria	Entrega	Relevância	Citada
E1	4c2ab64ffc9119884d87d90bf9d630c3	1	sem_itens	nao_entregue	0.884	não
E2	2d0a07007cc84621a2bc694505be4036	1	moveis_decoracao	atrasada	0.768	sim
E3	1e733f7b69d1fe917006989f0038e685	1	climatizacao	atrasada	0.691	sim
E4	65e3d04aef73660b0b2145ef3d5762cd	5	eletronicos	no_prazo	0.449	sim
E5	7eaac7481400e495ddfc2f5398aba896	1	utilidades_domesticas	atrasada	0.439	sim
E6	7d81592881b86d6ba09e4e5ae954a59d	1	ferramentas_jardim	no_prazo	0.417	sim
E7	364e74a2d89a35fa3fad2beaf96d8f17	1	moveis_escritorio	atrasada	0.402	sim
E8	a9e61054a0aac84e3346b255ef3d4e93	1	bebes	no_prazo	0.340	sim

B. Teste de Pergunta Agregada (Camada Analítica Determinística)

Execução de consulta agregada que exige contagem proporcional e identificação de padrões:

```
python scripts/perguntar.py "Quais são os principais problemas relatados pelos clientes?"
```

Status retornado: ok · Modo: analitico (roteamento automático validado)

Resumo Quantitativo Consolidado: Os principais problemas relatados são **pedido não recebido** com 3.406 avaliações (23,6%), seguido por **não recomenda / insatisfação geral** com 1.710 avaliações (11,8%) e **troca, devolução, cancelamento ou reembolso** com 1.704 avaliações (11,8%).

- Pedido não recebido (3.406 avaliações, 23,6%): Clientes continuam esperando ou o produto não foi entregue [E1][E2].
- Não recomenda / insatisfação (1.710 avaliações, 11,8%): Descumprimento de prazos e falta de consideração [E3][E4].
- Troca / Reembolso (1.704 avaliações, 11,8%): Pedidos cancelados indevidamente ou produtos avariados [E5][E6].
- Pedido incompleto (1.484 avaliações, 10,3%): Recebimento de apenas parte dos produtos comprados [E7][E8].
- Atraso na entrega (1.215 avaliações, 8,4%): Demora e descumprimento do prazo estimado [E9][E10].

Nota Metodológica: Contagens calculadas sobre 98.410 avaliações com apoio da taxonomia de temas auditada (precisão de 94,9%).

C. Teste do Gate de Abstenção (Anti-Alucinação / Guardrail)

Execução de consulta sem respaldo na base histórica (o Pix foi lançado em 2020; a base Olist cobre 2016–2018):

```
python scripts/perguntar.py "Como funciona o pagamento via Pix no Olist?"
```

Status retornado: sem_evidencias · Modo: rag · Chamada ao LLM: Abortada intencionalmente

Resposta de Abstenção: "Não encontrei avaliações relevantes para responder a esta pergunta na base de conhecimento (termos sem nenhuma ocorrência na base: 'pix', 'olist'; se houve erro de digitação ou você usou um sinônimo, reformule a pergunta). Não vou responder para não gerar informação sem suporte nos dados."

3. Avaliação Técnica contra o Estado da Arte (SOTA)

Ciência e Engenharia de Dados

- **Tratamento Explícito do Viés de Amostragem:** A equipe documentou que avaliações de nota 1 possuem texto em 77,2% dos casos, enquanto avaliações de nota 5 têm texto em apenas 37,8%. As análises quantitativas ponderaram adequadamente a base com comentário versus a base geral para não enviesar a percepção de negócio.
- **Mascaramento Robusto de PII:** Higienização de dados pessoais sensíveis (telefones, e-mails, CPFs e URLs) antes de qualquer etapa de indexação ou envio ao modelo gerativo, em total conformidade com a LGPD.
- **Unidade Documental sem Chunking Arbitrário:** Decisão sustentada pela distribuição do corpus (mediana de 9 palavras, máximo de 208 caracteres). Tratar 1 avaliação como 1 documento preserva o sentido completo e a rastreabilidade direta ao `review_id`.

Recuperação de Informação (Information Retrieval & NLP)

- **Busca Híbrida Balanceada:** Combinação de embeddings densos de última geração (`intfloat/multilingual-e5-base` com prefixos assimétricos `query:` e `passage:`) com BM25 esparsos otimizados com Snowball stemmer para a língua portuguesa, preservando negações críticas ("não", "nunca", "sem").
- **Fusão por Posto Recíproco (RRF):** A fusão por ranking elimina distorções decorrentes da disparidade de escalas de pontuação entre BM25 e similaridade por cosseno.
- **Re-ranking com Cross-Encoder:** O modelo reclassificador avalia a relação par pergunta-avaliação, garantindo que apenas evidências com alta relevância contextual compõem a janela de contexto.
- **Benchmark Comparativo Rigoroso:** O repositório documenta a evolução dos modelos, demonstrando que o `e5-base` com busca híbrida superou baselines clássicas (LSA/TF-IDF) e modelos menores, alcançando **MRR 1.0** e **Precisão@8 de 0.875**.

Inteligência Artificial Generativa e Guardrails RAG

- **Eliminação de Alucinações por Citação Estrita:** O prompt obriga o gerador a citar os identificadores [En] em cada assertiva. Um verificador pós-geração por expressão regular valida se todas as sentenças estão devidamente sustentadas.
- **Gate de Evidências Calibrado:** Limiares empíricos de similaridade e vocabulário impedem que o sistema responda quando a evidência recuperada for semanticamente insuficiente ou fora de escopo.
- **Consistência Numérica Assegurada:** Na camada analítica, o verificador pós-geração confere se todos os percentuais e contagens emitidos no texto são subconjuntos estritos da tabela calculada determinísticamente.